

# Wavelet alapú előfeldolgozás deep direkt vizuális odometriánál


Dámsa Levente  
Konzulensek:  
Dr. Szegletes Luca  
Dr. Blázovics László

# Deep direkt vizuális odometria

## Odometria

Vizuális odometria

Deep direkt vizuális odometria




[https://www.researchgate.net/figure/THE-ODOMETRY-SCHEME-The-relations-3-4-allow-to-compute-the-robot-estimated-position\\_fig6\\_267647029](https://www.researchgate.net/figure/THE-ODOMETRY-SCHEME-The-relations-3-4-allow-to-compute-the-robot-estimated-position_fig6_267647029)

# Deep direkt vizuális odometria

Odometria

**Vizuális odometria**

Deep direkt vizuális odometria



<https://www.researchgate.net/profile/Wang-Xin-12/publication/332103736/figure/fig2/AS:742384337952771@1554009627531/The-illustration-of-our-visual-odometry-framework-The-initial-state-vti-of-current.png>

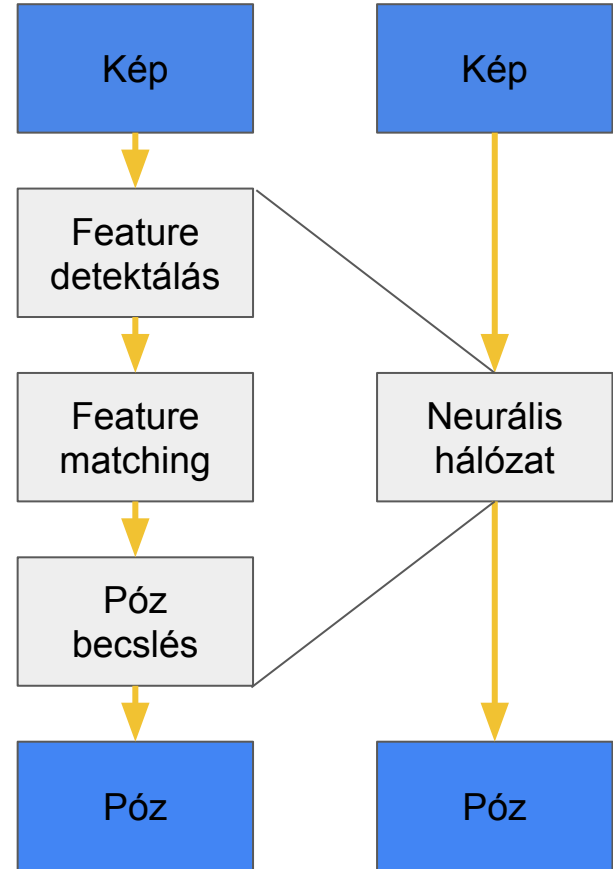
# Deep direkt vizuális odometria

Odometria

Vizuális odometria

## Deep direkt vizuális odometria

- feature based
- direkt



# Kihívások


Adathalmazok

Hálózat architektúra

- CNN
- RNN

Robosztusság

Hardver limitáció



forrás:

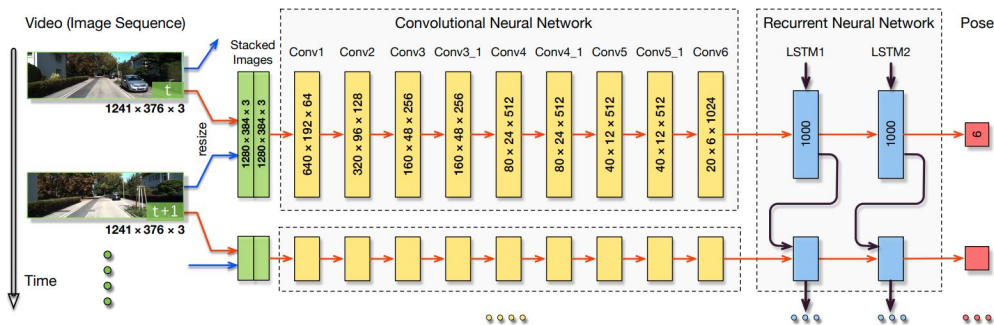
<https://www.forbes.com/sites/jonathanocallaghan/2021/04/22/nasas-perseverance-rover-has-made-oxygen-on-mars-for-the-first-time-ever/>

# Cél

Hálózat: DeepVO

Neurális hálózat csökkentése

Jobb reprezentáció keresése



forrás: <https://arxiv.org/abs/1709.08429>

# Wavelet transzformáció

Fourier transzformáció limit

Alkalmazások:


- Képtömörítés (JPEG)
- Agyi jelek
- Zajszűrés
- Éldetektálás

Continuous Wavelet Transform (CWT)

$$T(a, b) = \frac{1}{\sqrt{a}} \int_{-\infty}^{\infty} x(t) \psi^* \left( \frac{t-b}{a} \right) dt$$


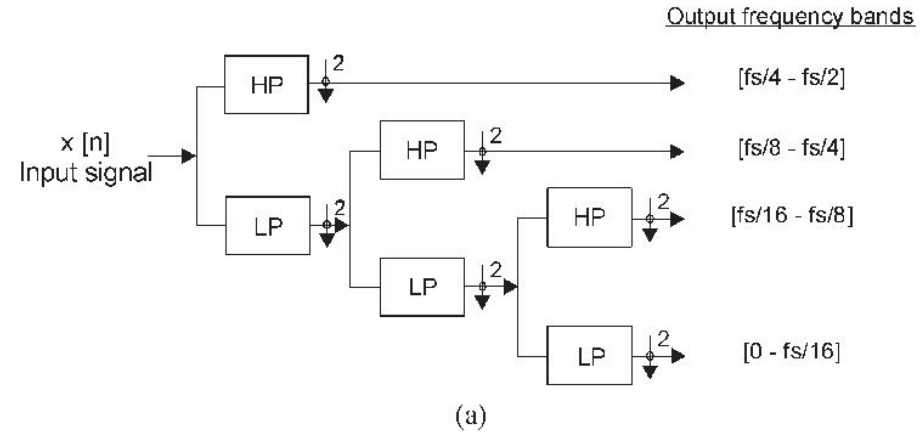
Discrete Wavelet Transform (DWT)

$$T_{m,n} = \int_{-\infty}^{\infty} x(t) \psi_{m,n}(t) dt$$



# Diszkrét Wavelet transzformáció

Hatékonyan implementálható filter bankokkal



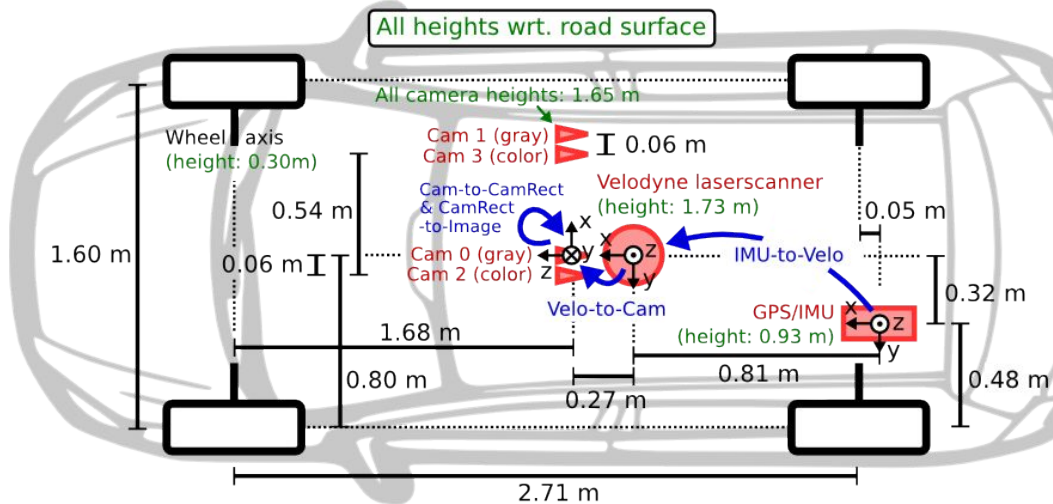


# KITTI

## 11 útvonál

10 FPS

## Ground truth trajektória



forrás: <http://www.cvlibs.net/datasets/kitti/>

# Wavelet alkalmazása

Feldolgozás:

- **Összes együttható**
- Együtthatók részhalmaza
- Hálózat kimenetén IDWT
- 3D wavelet

Módosítás:

- Bemenet méret csökkentése
- Hálózat egyszerűsítése
- FPGA használata




# Wavelet alkalmazása

Feldolgozás:

- Összes együtttható
- **Együttthatók részhalmaza**
- Hálózat kimenetén IDWT

Módosítás:


- Bemenet méret csökkentése
- Hálózat egyszerűsítése
- FPGA használata





# Motherwavelet választása

Szakirodalom:

- kis kompakt tartó
- ortogonális/biortogonális tulajdonság
- dbN, haar, sym



db2




db10






# Wavelet dekompozíció szint kiválasztása

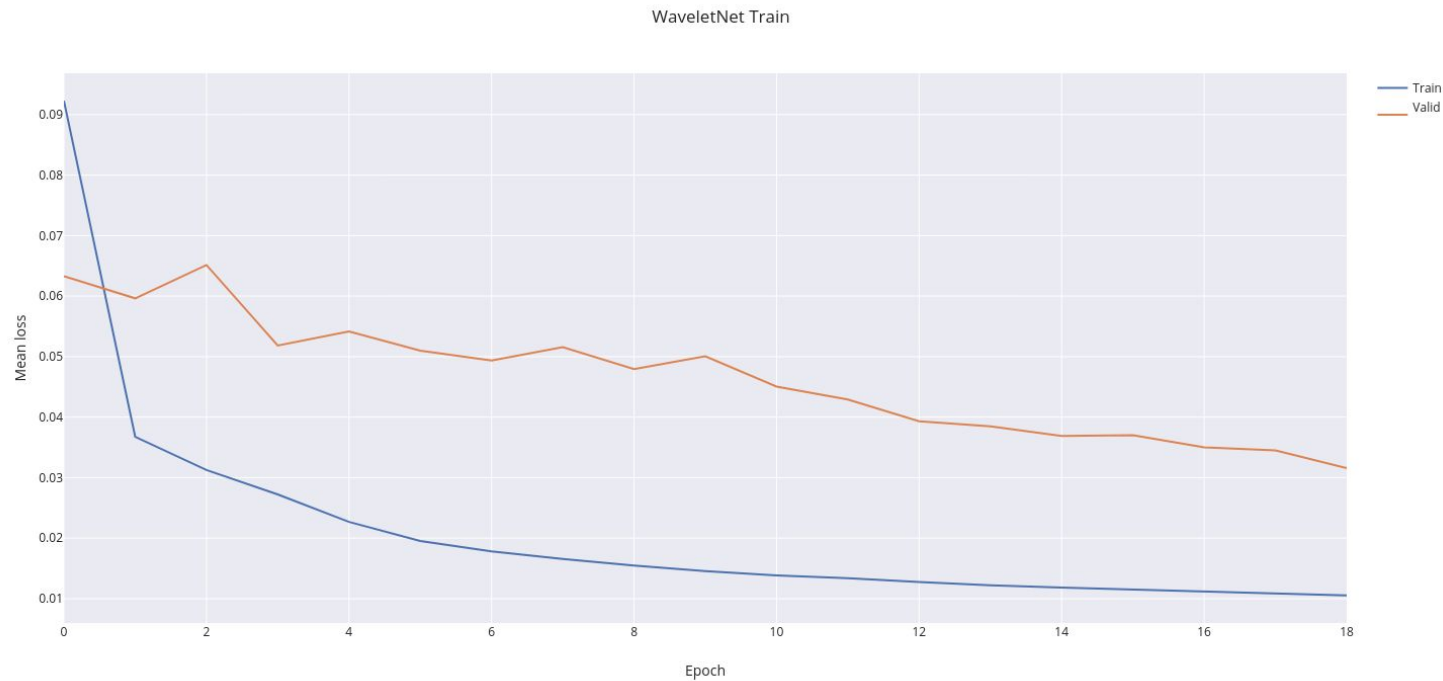


3 szint



5 szint

# Tanítás

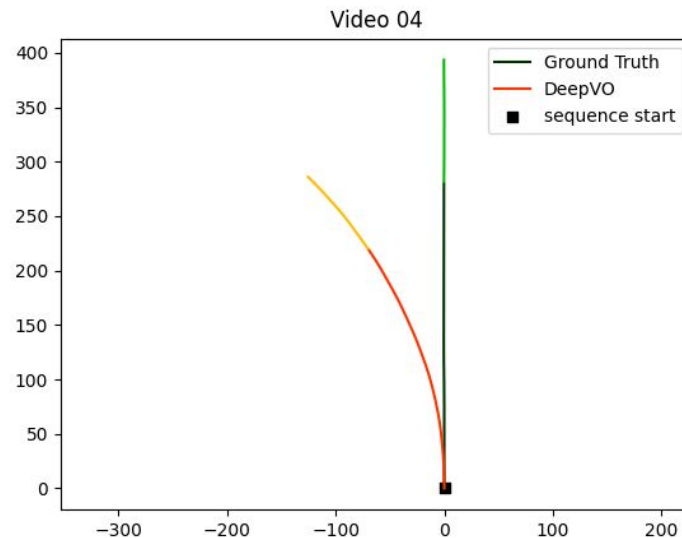
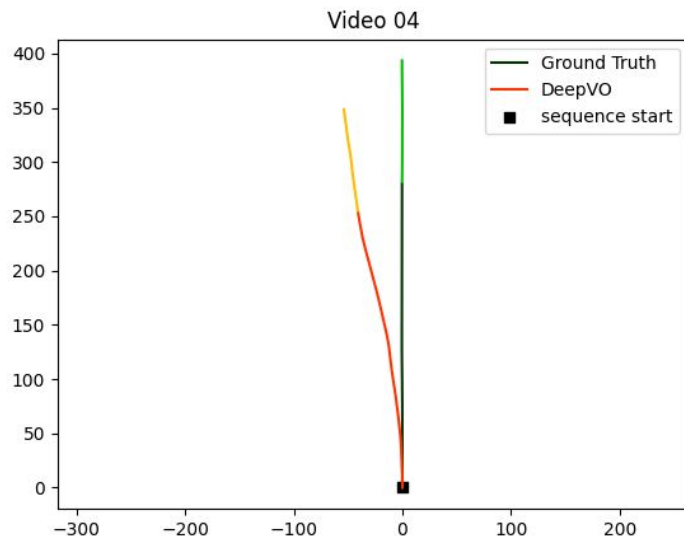


# Eredmények

Route	B_translation	W_translation	B_rotation	W_rotation
4	20.01	7.29	462.98	1931.91
5	575.40	200.89	31452.44	47205.97
7	286.71	204.87	4811.23	4081.76
9	504.15	190.41	19843.53	252777.87
10	358.78	153.42	7069.71	86960.68

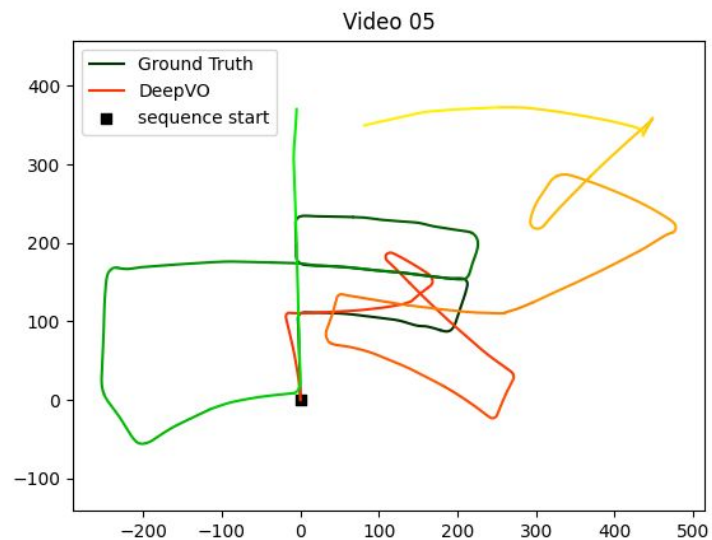
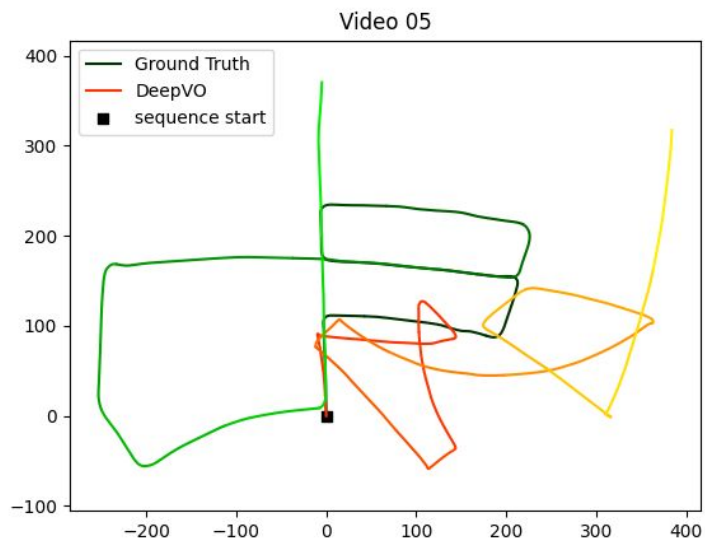
1. táblázat. MSE hibaértékek baseline vs wavelet

# Trajektóriák - test


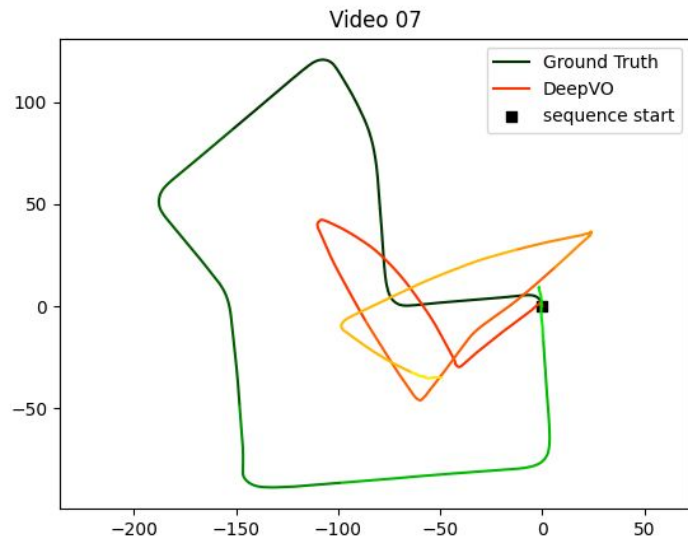




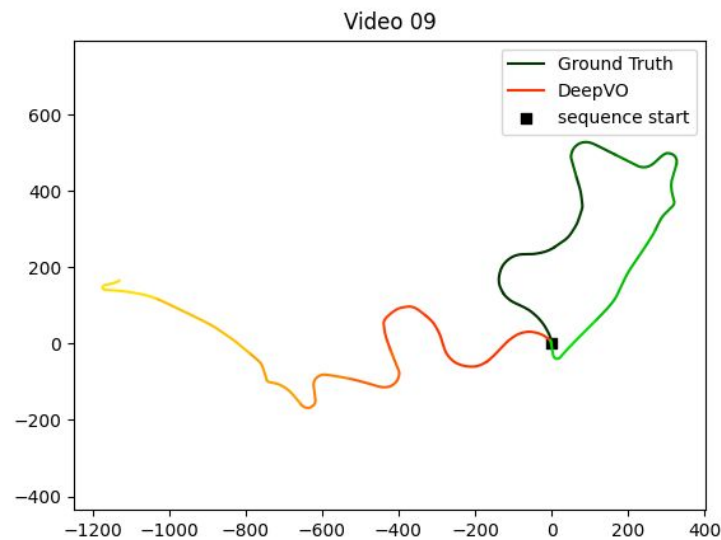

# Trajektóriák - train



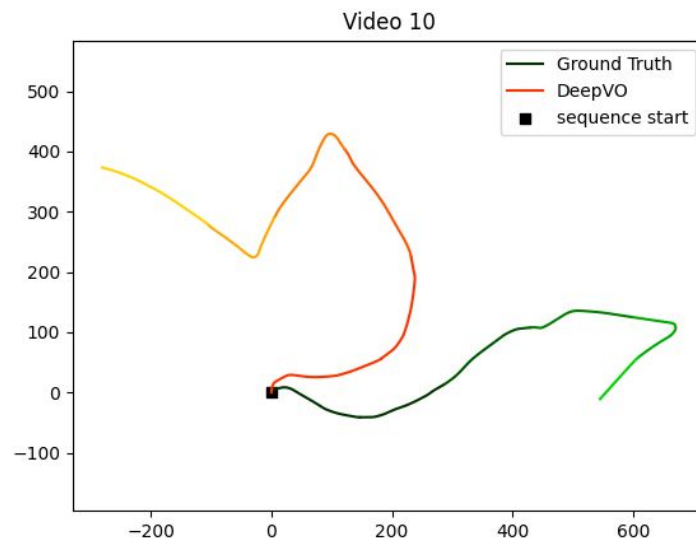
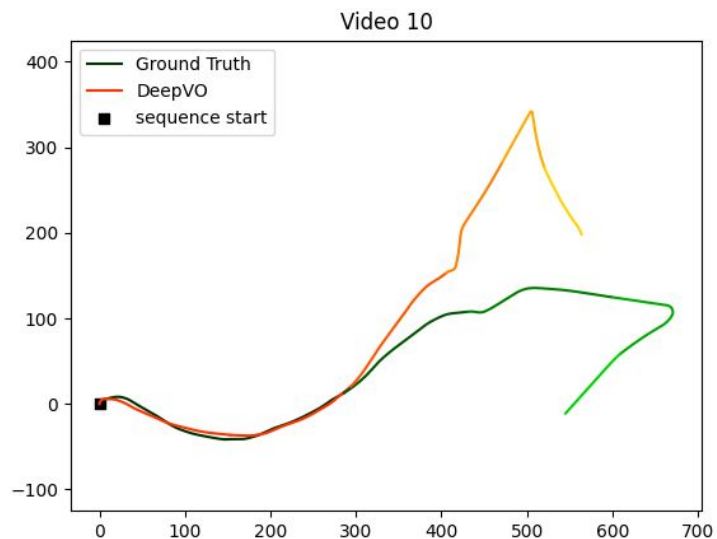
# Trajektóriák - test



# Trajektóriák - train



# Trajektóriák - test



# Csökkentett hálózat



CNN rétegek kivétele( 9 -> 6 )

RNN hálózat rejtett rétegének csökkentése (1000 -> 500)

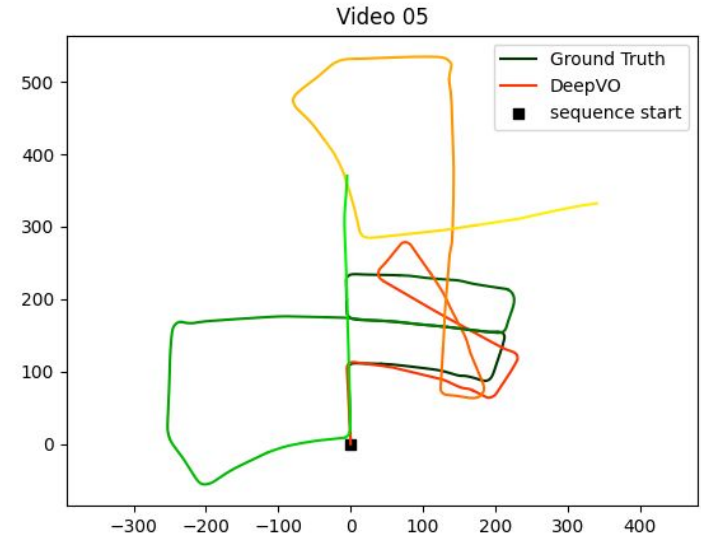
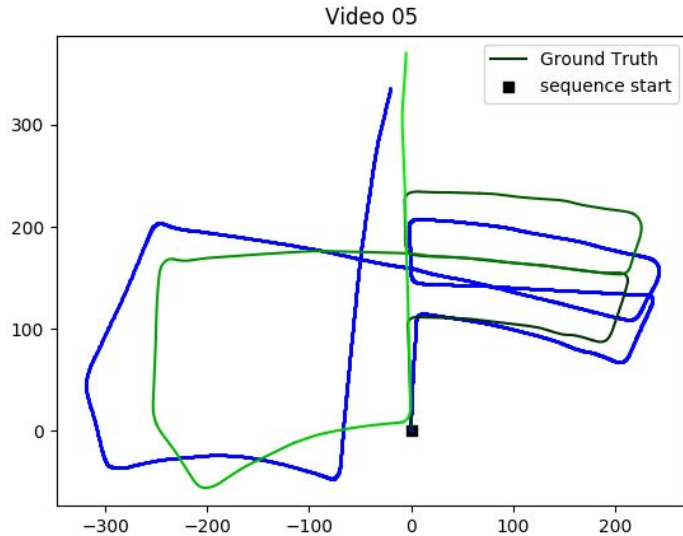
Tanítás: kb. 100 epoch

Baseline: DeepVO eredeti (200 epoch)



# Trajektóriák - Eredeti vs. 100 epoch - test



# Trajektóriák - Eredeti vs. 100 epoch - train





# Trajektóriák - Eredeti vs. 100 epoch - test







# Trajektóriák - Eredeti vs. 100 epoch - train



# Trajektóriák - Eredeti vs. 100 epoch - test



# Továbbfejlesztési lehetőségek

## További tanítás

- több epoch
- más adathalmazok

## Más architektúrák

Dekompozíciós szint és wavelet típus, mint hiperparaméter

Lidar, IMU sensor fusion

Alkalmazás 5G drónon

# Kérdések

- A bevezetőben (1. fejezet) azt írja: "Ezen deep learning alapú algoritmusok felváltották a klasszikus módszereket, azonban a SLAM, és a vizuális odometria területén még nem történt meg az áttörés." Az irodalom alapján van-e ennek műszaki jellegű oka, vagy egyszerű konzervativizmus áll mögötte?
- A wavelet feldolgozást a kisebb neurális háló mérettel indokolja. (1. fejezet) Mekkora számítási kapacitás, illetve idő áll rendelkezésre, mennyire fontos ez a redukció?
- A 7.2. alfejezetben bemutatja, hogy a translációs hiba csökkent, a rotációs pedig nőtt a wavelet alkalmazásakor. Mi lehet ennek az oka?
- Mit gondol, lehetséges lenne-e a wavelet transzformáció jelenleg manuálisan meghatározott paramétereit (pl. típus, dekompozíciós szint) a tanítási folyamat részeként hangolni? Javíthatná-e ez az eredményeket?
- Mennyiben változnának az eredmények, ha: 1) az alap és a javasolt módszer azonos epoch-számig lenne tanítva 2) mindkét módszer az eredeti cikk [DeepVO] szerint 200 epoch-ig lenne tanítva?